



UNIVERSIDAD DEL PACÍFICO

Hito 2 - Data Hunters

Integrantes

Tipacti Carrasco, Romy
Torres Valdivia, Fernando
Álvarez de la Torre, Arturo

Profesor

Espezúa Llerena, Soledad

Data Mining

Lima, 2026

1. Marco de Trabajo y Formulación Refinada	3
1.1. Formulación del Problema Aplicado y Justificación de Negocio	3
1.2. Usuario / Beneficiario	3
1.3. Objetivo de Análisis	3
2. Fuentes y Unidad de Análisis	3
2.1. Fuentes de Datos Actualizadas	3
2.2. Definición Estructurada de la Unidad de Análisis	4
3. Diagnóstico y Tratamiento de Calidad de Datos	4
4. Proceso de Integración y Granularidad	5
5. Análisis Exploratorio de Datos (EDA) e Interpretación	5
6. Transformación de Variables	5
7. Primera Matriz Analítica	6
7.1. Estructura y Variables Incluidas	6
7.2. Exclusiones Importantes	6
7.3. Repositorio en GitHub	7
8. Próximo Paso	7

1. Marco de Trabajo y Formulación Refinada

1.1. Formulación del Problema Aplicado y Justificación de Negocio

El Sistema Nacional de Programación Multianual y Gestión de Inversiones (**Invierte.pe**) del Ministerio de Economía y Finanzas (MEF) asigna anualmente importantes recursos para el desarrollo de infraestructura pública en el Perú. No obstante, en la administración pública operan dos sistemas informáticos desintegrados:

- **Seguimiento_PI** (MEF): Registra la ejecución presupuestal y financiera (certificación, devengado y girado).
- **Proceso_Seleccion** (MEF): Registra las contrataciones, licitaciones y valorizaciones del avance físico de obra.

Problemática Crítica: La falta de conciliación periódica entre ambas fuentes impide detectar oportunamente un patrón recurrente de ineficiencia y riesgo fiscal: **proyectos de inversión con gasto financiero acelerado que no se traduce en avance físico real** (por ejemplo, obras con más del 80% de ejecución presupuestal pero apenas 20% o 30% de avance físico certificado). Este descalce es el síntoma precursor de sobrecostos presupuestales, adendas contractuales, arbitrajes y paralización de obras ("elefantes blancos").

1.2. Usuario / Beneficiario

- **Contraloría General de la República:** Para priorizar auditorías preventivas sobre obras con riesgo de sobrecosto o abandono.
- **Ministerio de Economía y Finanzas (MEF) y Unidades Ejecutoras:** Para optimizar la asignación presupuestal y la supervisión de proyectos activos.
- **Ciudadanía:** Beneficiaria final del funcionamiento oportuno y transparente de las obras públicas.

1.3. Objetivo de Análisis

Segmentar y perfilar el portafolio de obras públicas activas para identificar conglomerados con descalce crítico financiero-físico y detectar anomalías en la velocidad de ejecución presupuestal, construyendo una matriz analítica reproducible a nivel de Proyecto de Inversión Pública (**CUI**).

2. Fuentes y Unidad de Análisis

2.1. Fuentes de Datos Actualizadas

- **Seguimiento_PI:** Registros presupuestales transaccionales del MEF (696,688 filas en estado crudo).

- **Proceso_Seleccion:** Registros de contrataciones y valorizaciones físicas del MEF (5,672,274 filas en estado crudo).

2.2. Definición Estructurada de la Unidad de Análisis

Para el modelado analítico (clustering y detección de anomalías), se estableció estrictamente la unidad de decisión: 1 fila = 1 Proyecto de Inversión Pública (CUI).

Dimensión Metodológica	Enfoque Hito 1 (Transaccional)	Enfoque Corregido Hito 2 (Unidad Proyecto CUI)	Justificación Técnica
Unidad de Análisis	Transacción presupuestal / Contrato	Proyecto de Inversión Pública (CUI)	Permite evaluar el ciclo de vida completo sin duplicidades.
Granularidad Seguimiento_PI	696,688 registros anuales	52,480 proyectos consolidados	Agregación groupby(CUI) sumando gasto histórico devengado y maduración.
Granularidad Proceso_Seleccion	5,672,274 registros contractuales	46,742 proyectos consolidados	Consolidación groupby(CUI) con avance físico certificado y montos adjudicados.
Tratamiento de Ruido	Códigos genéricos incluidos	197 códigos genéricos excluidos	Se retiraron bolsas presupuestales compartidas (ej. 2001621 de preinversión).
Tipo de Integración	Exploratoria / dispersa	Left Join 1 a 1 determinístico	Integración relacional limpia auditada con validate='one_to_one'.

3. Diagnóstico y Tratamiento de Calidad de Datos

1. **Exclusión de Ruido y Bolsas Presupuestales:** Se identificaron y retiraron 197 códigos genéricos (por ejemplo, el CUI 2001621 de preinversión) que acumulaban presupuestos globales no asignables a obras específicas.
2. **Duplicados e Inconsistencias:** Se eliminaron duplicados transaccionales mediante consolidación por CUI usando agregaciones determinísticas (groupby(CUI)).
3. **Tratamiento de Valores Faltantes y Delimitación de Población Objetivo:**
 - a. **52,480 CUI** componen el portafolio presupuestal real del MEF (tras excluir bolsas genéricas).
 - b. **35,472 CUI (67.59%)** cruzan en both al registrar asignación presupuestal y procesos contractuales.

- c. **1,978 CUI en Ejecución Activa (Universo Analítico de la Matriz):** Se seleccionaron aquellos proyectos con reporte simultáneo de avance físico de obra válido (>0%) y gasto devengado real (>0). Este filtro garantiza que el 100% de los datos en la matriz reflejen obras reales con métricas físicas y financieras auditables.

4. Proceso de Integración y Granularidad

- **Construcción de Tablas Agregadas:**
 - **Seguimiento_PI:** Se agrupó por CUI calculando la suma del costo de inversión, gasto devengado histórico, tiempo de maduración ($\text{anio_fin} - \text{anio_inicio} + 1$) y número de registros presupuestales.
 - **Proceso_Seleccion:** Se agrupó por CUI tomando el último porcentaje de avance físico certificado, monto adjudicado y total de contratos.
- **Tipo de Unión y Validación:** *Left Join* 1:1 auditado con `validate='one_to_one'`, empleando el `codigo_proyecto` (CUI) como clave primaria determinística.
- **Resultado del Emparejamiento:**
 - **35,472 registros emparejados (both):** Obras con registro presupuestal y licitación/contratación.
 - **17,008 registros no emparejados (left_only):** Obras ejecutadas por Administración Directa (personal/maquinaria propia) o compras directas <8 UIT.

5. Análisis Exploratorio de Datos (EDA) e Interpretación

1. **Relación entre Avance Físico y Gasto Financiero:** Se evidencia una marcada asimetría en la zona superior izquierda del plano cartesiano. Existe un grupo crítico de proyectos con más del 80% de ejecución presupuestal pero menos del 30% de avance físico certificado (por encima de la línea de equilibrio $\text{Gasto} = \text{Avance}$), representando obras en riesgo alto de sobrecostos o paralización.
2. **Comportamiento de la Brecha (Gasto - Avance):** La distribución presenta una tendencia central con dispersión hacia valores de descalce positivo, evidenciando desembolsos de dinero que superan el avance real de la obra.
3. **Proporción de Obras con Alerta por Nivel de Gobierno:** Los **Gobiernos Locales lideran ampliamente la tasa de sobregasto**, alcanzando un **47.6% de proyectos en alerta de gasto adelantado (>15%)**, frente a tasas sustancialmente menores en el Gobierno Nacional y Gobiernos Regionales. Esto demuestra mayor vulnerabilidad institucional y debilidad técnica en la supervisión de obras municipales distritales y provinciales.

6. Transformación de Variables

1. **Variables Derivadas de Negocio:**
 - a. **pct_ejecucion_financiera:** $(\text{gasto_total} / \text{costo_inversion}) * 100$.

- b. **brecha_gasto_avance**: $\text{pct_ejecucion_financiera} - \text{avance_fisico_pct}$.
 - c. **flag_gasto_adelantado**: Indicador binario de alerta (1 si $\text{brecha_gasto_avance} > 15\%$, 0 en caso contrario).
 - d. **tiempo_maduracion_anios**: $\text{anio_fin} - \text{anio_inicio} + 1$.
 - e. **gasto_anual_promedio**: $\text{gasto_total} / \text{tiempo_maduracion_anios}$.
2. **Discretización:**
- a. **pd.cut()**: Segmentación de **costo_inversion** en rangos normativos ("Pequeño", "Mediano", "Grande", "Megaproyecto") con mapeo ordinal explícito (0, 1, 2, 3).
 - b. **pd.qcut()**: División en terciles comparativos ("Bajo", "Medio", "Alto").
3. **Codificación Nominal**: One-Hot Encoding sobre **nivel_gobierno** empleando **pd.get_dummies(drop_first=True)** para evitar colinealidad perfecta (**gob_GOBIERNOS LOCALES**, **gob_GOBIERNOS REGIONALES**).
4. **Escalamiento**: Normalización **Min-Max** [0, 1] y estandarización **Z-Score** (=0, =1) aplicadas **únicamente a variables cuantitativas continuas** (**pct_ejecucion_financiera**, **avance_fisico_pct**, **brecha_gasto_avance**, **costo_inversion**, **gasto_total**, **tiempo_maduracion_anios**, **gasto_anual_promedio**, **n_registros_presupuesto**, **n_contratos**). No se escalaron binarias, dummies ni ordinales.

7. Primera Matriz Analítica

7.1. Estructura y Variables Incluidas

La primera matriz analítica está conformada por **1,978 observaciones (filas CUI)** y **13 características transformadas**, manteniendo **codigo_proyecto (CUI)** por separado para trazabilidad:

1. **pct_ejecucion_financiera** (Porcentaje de ejecución del presupuesto)
2. **avance_fisico_pct** (Porcentaje de avance físico certificado)
3. **brecha_gasto_avance** (Diferencia neta en puntos porcentuales)
4. **costo_inversion** (Monto total de inversión)
5. **gasto_total** (Monto devengado acumulado)
6. **tiempo_maduracion_anios** (Años en ejecución)
7. **gasto_anual_promedio** (Velocidad media de desembolso)
8. **n_registros_presupuesto** (Cantidad de partidas presupuestales)
9. **n_contratos** (Número de contratos registrados)
10. **flag_gasto_adelantado** (Variable binaria indicadora de alerta)
11. **tamano_inversion_ord** (Escala ordinal de inversión: 0 a 3)
12. **gob_GOBIERNOS LOCALES** (Dummy One-Hot)
13. **gob_GOBIERNOS REGIONALES** (Dummy One-Hot)

7.2. Exclusiones Importantes

- Se excluyeron 197 bolsas presupuestales genéricas no asignables a obras.
- Se excluyeron proyectos sin reporte de avance físico o sin devengado real (0%).
- Se omitieron identificadores y variables de texto no codificadas dentro del espacio vectorial de entrenamiento.

7.3. Repositorio en GitHub

El código fuente documentado, instrucciones de ejecución y archivos del proyecto se encuentran disponibles en el repositorio oficial de GitHub:

- **Enlace al Repositorio GitHub:**

https://github.com/RomyUP1411/data-mining-project/tree/main/Entrega_2

8. Próximo Paso

Implementar algoritmos de **Minería de Datos no supervisada (Clustering)** como K-Means, DBSCAN y Clustering Jerárquico sobre la matriz analítica estandarizada Z-Score para identificar perfiles de ejecución, agrupamientos de riesgo e identificar anomalías y proyectos atípicos con alto riesgo de sobrecosto o paralización.