Segmentación y Detección de Descalce en Obras Públicas de Invierte.pe Mediante Minería de Datos: Revisión Metodológica e Implementación Inicial

Fernando Torres Valdivia, Romy Tipacti Carrasco, Arturo Álvarez de la Torre
Curso: Data Mining
Universidad del Pacífico
Docente: Soledad Espezúa Llerena

***Resumen*—En la gestión de la inversión pública peruana, el desfase entre el desembolso financiero y el avance físico real de las obras constituye una causa crítica de ineficiencia y paralizaciones. En este Hito 3, presentamos la revisión metodológica y la implementación inicial de técnicas de agrupamiento no supervisado sobre una matriz analítica de 2 067 proyectos de inversión pública (CUI) del sistema Invierte.pe, integrando 12 atributos normalizados de ejecución presupuestal, contratación y gobernanza. Evaluamos comparativamente tres familias algorítmicas: particional (K-Means), basada en densidad (DBSCAN) y jerárquica aglomerativa (Ward). Los resultados preliminares muestran que K-Means con $K = 4$ logra aislar consistentemente proyectos anómalos de escala extrema (como la Línea 2 del Metro) y segmentar con claridad las obras municipales frente a las regionales e intermedias. Por su parte, DBSCAN ($\varepsilon = 1.8$, MinPts $= 24$) identifica un núcleo denso institucional y aísla un 8.4 % de obras atípicas con patrones contractuales y brechas críticas. Estos hallazgos sientan las bases para el modelado y perfilamiento predictivo que desarrollaremos en el Hito 4.**

***Index Terms*—minería de datos, agrupamiento no supervisado, inversión pública, Invierte.pe, descalce financiero-físico.**

I. Introducción

El Sistema Nacional de Programación Multianual y Gestión de Inversiones (Invierte.pe) administra la cartera de proyectos de inversión del Estado peruano. A pesar de los cuantiosos recursos públicos asignados cada año a obras de infraestructura vial, sanitaria, educativa y de salud, el seguimiento operativo de los proyectos enfrenta una brecha informacional crítica: la desarticulación técnica entre los sistemas transaccionales del Ministerio de Economía y Finanzas (MEF).

Específicamente, el módulo de *Seguimiento_PI* registra la ejecución presupuestal y financiera (certificación, compromiso, devengado y giro monetario), mientras que las plataformas de contrataciones del Estado (*Proceso_Seleccion* e Infobras) supervisan los contratos, licitaciones y valorizaciones mensuales del avance físico en campo.

Esta falta de conciliación sistemática propicia el surgimiento del fenómeno de *descalce*: proyectos que devengan un alto porcentaje de su presupuesto programado pero presentan avances físicos sustancialmente rezagados, o viceversa. Esta asimetría antecede de forma recurrente sobrecostos presupuestales, adendas sucesivas, litigios arbitrales y, en el escenario más severo, la paralización total de obras públicas (fenómeno popularmente conocido como "elefantes blancos").

Los principales usuarios y beneficiarios de nuestro trabajo son las unidades de control gubernamental de la Contraloría General de la República, la Dirección General de Programación Multianual de Inversiones del MEF y las oficinas de programación e inversiones de gobiernos regionales y locales.

El objetivo central de nuestro proyecto consiste en segmentar de manera no supervisada la cartera de obras públicas para descubrir tipologías estructurales de proyectos y caracterizar perfiles anómalos de descalce. En consecuencia, la pregunta principal que guía este estudio es: *£Es posible identificar tipologías estructurales de proyectos de inversión y aislar perfiles de alto descalce financiero-físico mediante técnicas de clustering no supervisado aplicadas sobre datos transaccionales del MEF?*

II. Datos y Representación Final

A partir del trabajo de extracción, limpieza e integración desarrollado en el Hito 2, consolidamos una matriz analítica reproducible disponible en nuestro repositorio institucional de GitHub[1]. En dicha base, la unidad de análisis corresponde unívocamente a un proyecto de inversión pública identificado mediante su Código Único de Inversión (CUI).

La muestra analizada abarca $N = 2\,067$ proyectos de inversión con ejecución registrada. Para la aplicación rigurosa de los algoritmos no supervisados, seleccionamos 12 variables numéricas y categóricas codificadas, representativas de cuatro dimensiones de negocio:

1. **Descalce y ejecución operativa:** porcentaje de ejecución financiera (`pct_ejecucion_financiera`), porcentaje de avance físico acumulado (`avance_fisico_pct`) y brecha de gasto versus avance físico (`brecha_gasto_avance`).
2. **Magnitud presupuestal:** costo actualizado de inversión (`costo_inversion`), gasto acumulado devengado (`gasto_total`) y gasto anual promedio (`gasto_anual_promedio`).
3. **Temporalidad:** tiempo de maduración en años desde la declaratoria de viabilidad

[1]Repositorio reproducible: https://github.com/RomyUP1411/data-mining-project

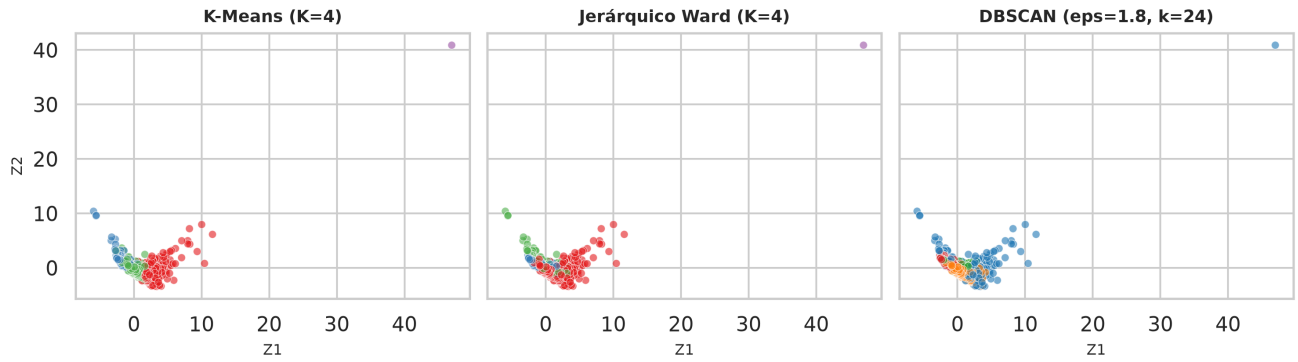


Figura 1. Proyección bidimensional mediante PCA de las particiones generadas por K-Means ($K = 4$), DBSCAN ($\varepsilon = 1.8$) y Agrupamiento Jerárquico (Ward, $K = 4$). Se observa la coherencia de grupos y el aislamiento de ruido/atipicidades.

(`tiempo_maduracion_anios`) y número de años con asignación presupuestal (`n_registros_presupuesto`).

4. **Complejidad y gobernanza:** número total de contratos derivados de procesos de selección (`n_contratos`), escala de inversión ordinal (`tamano_inversion_ord`), y variables dicotómicas de nivel de gobierno ejecutor (`gob_GOBIERNOS LOCALES` y `gob_GOBIERNOS REGIONALES`, tomando como nivel base al Gobierno Nacional).

Debido a que las variables presentan dispersiones monetarias en millones de soles junto a porcentajes y conteos discretos, aplicamos una estandarización previa mediante *StandardScaler* ($z = \frac{x-\mu}{\sigma}$), garantizando un espacio euclidiano equilibrado.

III. Metodología

Para caracterizar de forma robusta las tipologías de obras y detectar anomalías estructurales, adoptamos una estrategia de triangulación entre tres familias algorítmicas de minería de datos:

1. K-Means (Particional): Minimiza la inercia o varianza intracluster mediante la relocalización iterativa de centroides. Es computacionalmente eficiente y permite perfilar arquetipos representativos de la cartera pública, asumiendo clusters convexos.

2. DBSCAN (Basado en Densidad): Agrupa observaciones situadas en zonas de alta densidad separadas por regiones de baja densidad, dependiendo de dos parámetros: el radio de vecindad (ε) y la cantidad mínima de puntos vecinos (MinPts). DBSCAN es idóneo para nuestro problema pues aísla proyectos atípicos bajo la categoría explícita de ruido (etiqueta -1).

3. Jerárquico Aglomerativo (Ward): Construye un árbol jerárquico uniendo de abajo hacia arriba los grupos que producen el menor incremento en la suma de cuadrados del error. Permite examinar la solidez del agrupamiento y detectar posibles encadenamientos indeseados.

Adicionalmente, implementamos Análisis de Componentes Principales (PCA) para reducir la dimensionalidad y proyectar las asignaciones en un plano bidimensional interpretable (Fig. 1).

IV. Diseño Experimental

Evaluamos metódicamente diversas configuraciones de hiperparámetros apoyándonos en métricas cuantitativas de validación interna:

- **Para K-Means:** Exploramos valores de $K \in [2, 10]$. Analizamos la inercia (método del codo), el coeficiente de Silueta media y el índice de Davies-Bouldin.
- **Para DBSCAN:** Establecimos MinPts $= 2 \times d = 24$, donde $d = 12$ es la cantidad de atributos. Graficamos la distancia euclidiana ordenada al 24-ésimo vecino más cercano (k-distancias, Fig. 3) para identificar la zona de curvatura máxima, evaluando luego valores de $\varepsilon \in \{1.5, 1.8, 2.0, 2.2\}$ en términos de porcentaje de ruido y cohesión del núcleo.
- **Para Jerárquico:** Comparamos cuatro funciones de enlace (`ward`, `complete`, `average`, `single`) evaluando la distribución de tamaños y la resistencia al encadenamiento.

Los resultados del diseño experimental se resumen en la Tabla II.

V. Resultados Preliminares

Los ensayos experimentales proporcionan hallazgos claros sobre la estructura latente de los proyectos de inversión pública en el Perú:

V-A. Tipologías Descubiertas mediante K-Means

Como se visualiza en la Fig. 2, la inercia desciende significativamente hasta $K = 4$, a partir del cual las ganancias marginales se estabilizan. La elección de $K = 4$ resulta sustantivamente justificada porque separa con nitidez los niveles institucionales y aisla la distorsión de megaproyectos:

- **Cluster 0 ($N = 809$, 39.1 %):** Proyectos intermedios liderados por el Gobierno Nacional (55.4 %) y Gobiernos

Cuadro I
PERFIL ANALÍTICO PROMEDIO DE LOS SEGMENTOS IDENTIFICADOS (K-MEANS, $K = 4$)

Cluster	N	Pje.	Costo Inv. (S/.)	Ejec. Fin. (%)	Avance Físico (%)	Brecha (%)	Maduración (años)	N° Contratos
Cluster 0 (Nacional / Regional Mediano)	809	39.1 %	13 676 717	53.7 %	78.3 %	-24.6 %	11.4	132.1
Cluster 1 (Megaproyecto Atípico / Metro)	1	0.05 %	12 075 449 652	15.2 %	50.4 %	-35.2 %	13.0	72.0
Cluster 2 (Gobiernos Locales / Municipal)	924	44.7 %	5 792 762	59.4 %	78.6 %	-19.3 %	9.3	129.0
Cluster 3 (Complejidad Multicontrato)	333	16.1 %	168 594 124	35.3 %	63.9 %	-28.6 %	14.1	362.8

Cuadro II
COMPARACIÓN DE CONFIGURACIONES EVALUADAS

Método	Configuración	Criterio / Métrica	Resultado
K-Means	$K = 2$	Silueta / Davies-Bouldin	0.230 / 1.780
K-Means	$K = 3$	Silueta / Davies-Bouldin	0.231 / 1.191
K-Means	$K = 4$ **(Seleccionado)**	Silueta / Davies-Bouldin	**0.203 / 1.442**
K-Means	$K = 5$	Silueta / Davies-Bouldin	0.214 / 1.341
K-Means	$K = 6$	Silueta / Davies-Bouldin	0.215 / 1.236
DBSCAN	$\varepsilon = 1.5$, MinPts $= 24$	% Ruido / Silueta (core)	14.1 % / 0.260
DBSCAN	$\varepsilon = 1.8$, **MinPts** $= 24$	% Ruido / Silueta (core)	**8.4 % / 0.245**
DBSCAN	$\varepsilon = 2.0$, MinPts $= 24$	% Ruido / Silueta (core)	6.3 % / 0.238
DBSCAN	$\varepsilon = 2.2$, MinPts $= 24$	% Ruido / Silueta (core)	5.4 % / 0.270
Jerárquico	Complete ($K = 4$)	Distribución / Silueta	2053/10/3/1 / 0.637
Jerárquico	Average ($K = 4$)	Distribución / Silueta	2054/9/3/1 / 0.670
Jerárquico	Single ($K = 4$)	Distribución / Silueta	2062/3/1/1 / 0.690
Jerárquico	**Ward** ($K = 4$)	Distribución / Silueta	1117/544/405/1 / 0.209

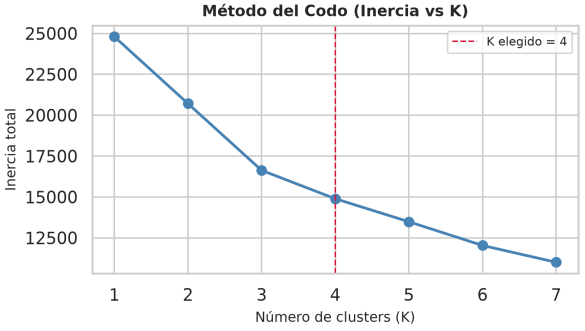


Figura 2. Curva del codo (Inercia vs. K) para el agrupamiento con K-Means.

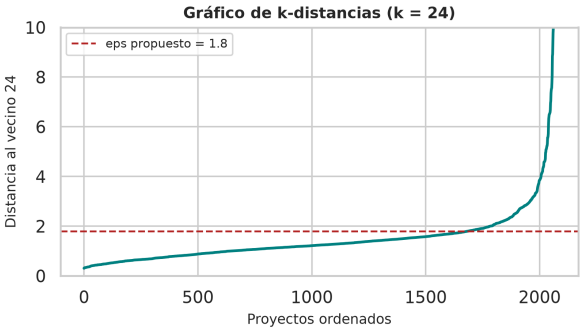


Figura 3. Gráfico de k-distancias ($k = 24$) para la calibración de ε en DBSCAN.

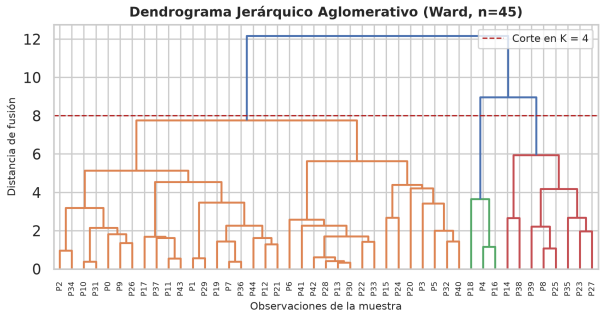


Figura 4. Dendrograma aglomerativo con enlace Ward y línea de corte en $K = 4$.

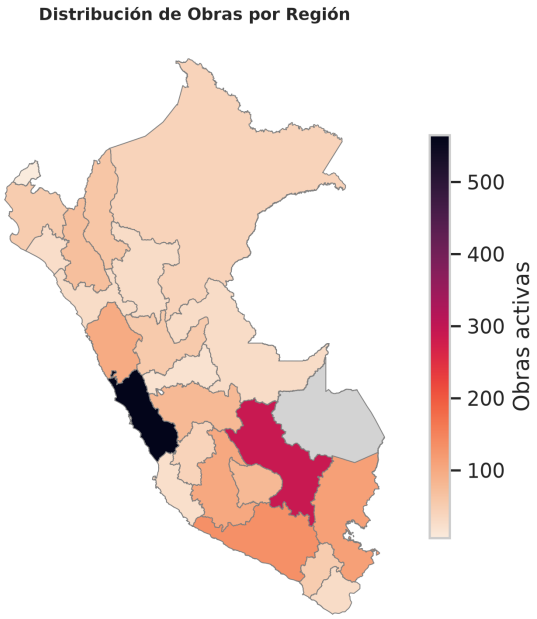


Figura 5. Concentración regional de proyectos analizados según cartografía IGN.

Regionales (44.6 %). Presentan un costo medio de S/. 13.7M, con un avance físico promedio de 78.3 % y una ejecución financiera de 53.7 % (brecha promedio de -24.6 %). Son obras de infraestructura vial y salud de mediana complejidad.

- **Cluster 1 ($N = 1$, 0.05 %):** Caso atípico aislado que corresponde a la "Línea 2 y Ramal Av. Faucett - Gambetta de la Red Básica del Metro de Lima y Callao" (CUI 2190333). Su costo supera los S/. 12 075 millones. Aislarlo en un cluster unitario evita distorsionar los centroides de los demás grupos.
- **Cluster 2 ($N = 924$, 44.7 %):** Obras eminentemente municipales (97.5 % de Gobiernos Locales), de menor envergadura (S/. 5.8M en promedio) y menor tiempo de maduración (9.3 años), con una ejecución física y financiera relativamente más dinámica (78.6 % y 59.4 %, respectivamente).
- **Cluster 3 ($N = 333$, 16.1 %):** Obras complejas con severa fragmentación contractual (promedio de 362.8 contratos por proyecto) y maduración muy prolongada (14.1 años), ejecutadas en su mayoría por Gobiernos Regionales (56.5 %) y Nacional (31.2 %). Exhiben un avance financiero rezagado (35.3 %) frente a su avance físico (63.9 %).

V-B. Detección de Ruido Estructural con DBSCAN

La inspección de la rodilla en el gráfico de k-distancias (Fig. 3) sugiere que entre $\varepsilon = 1.6$ y $\varepsilon = 1.9$ se ubica la transición de densidad. Al adoptar $\varepsilon = 1.8$ con MinPts $= 24$, DBSCAN identificó 3 conglomerados densos y categorizó a 174 proyectos (8.4 % del total) como ruido atípico. Al examinar cualitativamente estas 174 obras, encontramos que corresponden a proyectos con esquemas de contratación hipertrofiados (cientos de adendas) o descalces financieros severos, confirmando la utilidad de DBSCAN como mecanismo objetivo de triaje para auditorías de control.

V-C. Estabilidad Jerárquica y Análisis Territorial

La comparación de métodos jerárquicos (Tabla II) demostró que los enlaces `complete`, `average` y `single` fallan al concentrar más de 2 050 observaciones en un solo nodo debido a su alta sensibilidad a outliers. El enlace de Ward (Fig. 4), en cambio, arrojó una jerarquía armónica (1 117, 544, 405 y 1) que respalda la segmentación en 4 perfiles.

Por otro lado, el mapeo espacial mediante GeoPandas (Fig. 5) revela una marcada concentración de la muestra en departamentos del sur andino como Cusco (289 proyectos) y Puno, así como en Lima y Áncash. Esto sugiere que las capacidades locales y las fuentes de canon regional inciden directamente en los volúmenes de inversión ejecutada.

VI. Problemas, Limitaciones y Trabajo Pendiente

Durante esta fase inicial identificamos las siguientes limitaciones:

1. **Dominancia de megaproyectos:** Obras como la Línea 2 ejercen una atracción desmedida sobre los centroides si no se aíslan adecuadamente.
2. **Heterogeneidad de densidades:** La disparidad operativa entre municipalidades rurales y ministerios centrales complica el ajuste de un ε único en DBSCAN.
3. **Registro intermitente de avance físico:** Ciertas entidades registran valorizaciones físicas con retrasos considerables en Infobras, lo que puede sobrestimar el descalce aparente de forma coyuntural.

Actividades pendientes para el Hito 4:

- Realizar validación cruzada y remuestreo (*bootstrapping*) para medir la estabilidad y consistencia de los centroides de K-Means.
- Integrar variables de sector funcional (Transportes, Educación, Saneamiento) para enriquecer el perfilamiento de cada segmento.
- Formular reglas de decisión o un modelo de clasificación supervisada que aproveche las etiquetas de cluster y ruido para alertar tempranamente sobre proyectos en riesgo de paralización.

Referencias

Referencias

[1] Ministerio de Economía y Finanzas del Perú (MEF), "Sistema Nacional de Programación Multianual y Gestión de Inversiones (Invierte.pe)," Marco Normativo, Lima, Perú, 2024.

[2] Contraloría General de la República del Perú, "Reporte de Obras Paralizadas en el Territorio Nacional a Diciembre 2023," Lima, Perú, 2024.

[3] M. Ester, H.-P. Kriegel, J. Sander, y X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," en *Proc. 2nd ACM KDD*, pp. 226–231, 1996.

[4] J. MacQueen, "Some methods for classification and analysis of multivariate observations," en *Proc. 5th Berkeley Symp. Math. Statist. Prob.*, vol. 1, pp. 281–297, 1967.

[5] J. H. Ward Jr., "Hierarchical grouping to optimize an objective function," *J. Amer. Statist. Assoc.*, vol. 58, no. 301, pp. 236–244, 1963.

[6] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.